

UNIVERSIDAD TECNOLÓGICA METROPOLITANA

Informe Actividad 4

Asignatura: Infraestructura para Ciencia de Datos

Nombre: Fabrizio Andrés Larco Jorquera

Profesor: Michael Miranda

Fecha: 13 de mayo de 2026

1. Resumen Ejecutivo

El presente informe documenta la evaluación de estrategias de escalabilidad y optimización de almacenamiento aplicadas a un dataset de telemetría masiva de 1,000,000 de registros. A través de cuatro experimentos, se cuantificó el impacto del procesamiento por fragmentos (chunks) y la migración a formatos columnares (Parquet). Los hallazgos demuestran que el procesamiento incremental reduce significativamente el uso de RAM, mientras que el formato Parquet optimiza el espacio en disco en un 72.54% y acelera las consultas selectivas casi 10 veces en comparación con el formato CSV tradicional.

2. Marco Teórico

- **Paralelismo de Datos:** Distribución de grandes volúmenes de datos a través de múltiples unidades de cómputo para ejecutar la misma instrucción simultáneamente.
- **Overhead:** El costo de tiempo adicional requerido por el sistema operativo para coordinar procesos o fragmentos, el cual puede influir en la eficiencia si la carga es pequeña.
- **Procesamiento Incremental (Chunks):** Técnica que consiste en dividir un dataset masivo en fragmentos manejables para evitar el desbordamiento de la memoria volátil (RAM).
- **Almacenamiento Columnar (Parquet):** Formato de archivo optimizado que almacena datos por columnas, permitiendo compresión superior y acceso eficiente.

3. Metodología Experimental

3.1 Configuración de Hardware

- **CPU:** AMD Ryzen 5 5500 (12 hilos lógicos).
- **GPU:** MSI NVIDIA GeForce RTX 3050 (6 GB).
- **RAM:** 32 GB.

3.2 Descripción de Experimentos

1. **Experimento A:** Generación de telemetría sintética para 1,000,000 de registros únicos de partidas de Overwatch 2.
2. **Experimento B:** Análisis de trade-offs entre carga monolítica y carga incremental (chunks) midiendo RAM y tiempo.
3. **Experimento C:** Cálculo incremental de métricas (sanación total) por héroe de soporte en rangos altos.
4. **Experimento D:** Migración de CSV a Parquet para evaluar eficiencia de almacenamiento y velocidad de lectura columnar.

4. Resultados

4.1 Experimento B


Estrategia	Tamaño de Bloque	Tiempo (s)	Memoria RAM (MB)
Carga Monolítica	1,000,000	1.53	174.91
Chunk Processing	50,000	1.60	100.13
Chunk Processing	100,000	1.62	16.89
Chunk Processing	200,000	1.66	25.65

4.2 Experimento C


Héroe de Soporte	Sanación Total (Diamond/Master)
Ana	1,257,006,595
Juno	1,260,549,969
Kiriko	1,262,123,433
Mercy	1,255,327,763
Mizuki	1,258,292,276

4.3 Experimento D

Métrica de Comparación	CSV Tradicional	Parquet (Optimizado)	Mejora
Tamaño en Disco	82.20 MB	22.57 MB	72.54% ahorro
Lectura 1 Columna	0.5177 s	0.0564 s	9.17x más rápido




(exp_B_comparativa_rendimiento.png)



(exp_C_metricas_soporte.png)

Figura 4: Eficiencia del Formato Columnar (Parquet)



(exp_D_parquet_analisis.png)

5. Análisis y Discusión

El análisis revela que la carga monolítica representa un riesgo crítico para la estabilidad de la infraestructura cuando los datasets escalan. El uso de fragmentos de 100,000 filas demostró ser el punto óptimo de eficiencia, manteniendo un uso de RAM mínimo sin sacrificar el rendimiento. Asimismo, el Experimento D valida la superioridad del formato columnar: la reducción de tamaño y la velocidad de acceso justifican la migración para procesos de analítica pesada.

6. Decisiones Técnicas por Escenario

- **Servidor Local:** Se recomienda el uso de multiprocesamiento para tareas lógicas pesadas y procesamiento incremental para evitar cuellos de botella en la RAM.
- **Múltiples Fuentes:** Es fundamental el uso de asincronía para gestionar peticiones de red simultáneas sin bloquear el servidor principal.
- **Plataforma Cloud:** Para Big Data, es obligatorio migrar de formatos basados en filas a infraestructuras columnares como Parquet para optimizar costos y tiempos.

7. Conclusiones y Recomendaciones

Se concluye que la eficiencia de una infraestructura de datos no depende de la potencia bruta, sino de la alineación entre el algoritmo y el paradigma de procesamiento. También se recomienda la estandarización del formato Parquet para la telemetría histórica y el uso de flujos incrementales para cualquier dataset que supere los límites de la memoria física.

8. Anexos

- Código Fuente: Disponible en el repositorio adjunto.
- Apoyo técnico para confección: Gemini Pro.